



Gymnázium J. K. Tyla

Úvod do agentického AI a harness pro automatizovaný softwarový vývoj

ODBORNÁ PRÁCE

Autor práce: Patrik Marius, 4.D

Vedoucí práce: Michal Dočekal

Prohlášení

Prohlašuji, že jsem tuto studentskou odbornou práci vypracoval/a samostatně pod dohledem vedoucího uvedeného na první straně. Všechny použité zdroje jsou uvedeny v seznamu zdrojů a informace z nich získané jsou v textu řádně označeny odkazem na zdroj. Souhlasím s tím, aby tištěná forma práce byla uchována na Gymnázium J. K. Tyla a tam používána jako tištěný zdroj např. pro další studentské práce či pro prezentaci vzdělávání na GJKT.

V Hradci Králové dne

Podpis autora práce:

.....

Anotace

Tato odborná práce se zabývá principy agentního inženýrství (*agentic engineering*) a architekturou řídicích harnessů pro automatizovaný vývoj softwaru. Praktickým přínosem práce je návrh a implementace systému DarkFactory — agentního harnessu instalovatelného jako aplikace pro platformu GitHub (GitHub App). Systém usiluje o maximální možnou míru automatizace vývojového cyklu od sémantické analýzy požadavků v GitHub Issues, přes technické plánování, až po generování kódu a vystavení pull requestu. Práce reflektuje, že současné agentní systémy nelze vnímat jako plně autonomní: jazykové modely vyžadují deterministické mantinely proti uvíznutí v nekonečných cyklech, správu kontextu bez sémantického posunu a především kontinuální zapojení člověka formou schvalovacích bran (*Human-in-the-loop*).

Klíčová slova

agentní inženýrství, řídicí harness, GitHub App, DarkFactory, automatizace vývoje, orchestrace agentů, jazykové modely

Annotation

This thesis explores the foundational principles of agentic engineering and harness architecture for automated software development. The practical contribution of the work is the design and implementation of DarkFactory — an agentic harness installable as a GitHub App. The system aims to maximize the automation of the software engineering lifecycle, ranging from issue interpretation in GitHub Issues and technical planning to code generation and pull request delivery. The thesis emphasizes that modern agentic systems cannot be considered fully autonomous: large language models require deterministic guardrails against infinite loops, rigorous context management without semantic drift, and indispensable human-in-the-loop governance via approval gates.

Keywords

agentic engineering, harness architecture, GitHub App, DarkFactory, software development automation, agent orchestration, language models

Obsah

Prohlášení	2
Anotace	3
Klíčová slova	3
Annotation	3
Keywords	3
1 Úvod	7
1.1 Motivace a vymezení problému	7
1.2 Cíl práce a výzkumné otázky	7
1.3 Metodika práce	8
2 Teoretická část	9
2.1 Deterministická vývojová infrastruktura	9
2.1.1 Úvod do deterministické infrastruktury	9
2.1.2 Větvě a větvová izolace	9
2.1.3 Model pull requestu	9
2.1.4 Strategie slučování (Squash and Merge)	10
2.1.5 Kontinuální integrace (CI)	10
2.1.6 Požadované kontroly (Required Checks)	10
2.2 Kognitivní jádro a správa kontextového okna	10
2.2.1 Úvod do velkých jazykových modelů	10
2.2.2 Tokeny, tokenizace a embedding	11
2.2.3 Tahy a správa KV cache	11
2.2.4 Kompakce kontextu a ztrátová komprese	11
2.2.5 Sémantický posun (Semantic Drift)	12
2.2.6 Alternativní paměťové architektury (RAG a stavový graf)	12
2.2.7 Degradace pozornosti (Context Rot)	12
2.2.8 Promptové inženýrství a negativní instrukce	12
2.3 Architektura řídicího harnessu a orchestrace	13
2.3.1 Úvod do řídicích harnessů	13
2.3.2 Autonomní agent vs. konverzační chatbot	13
2.3.3 Prováděcí cyklus ReAct	13
2.3.4 Běhové prostředí nástrojů a pískoviště (Sandbox)	14
2.3.5 Patologie divergence: perseverace a oscilace	14
2.3.6 Deterministické pojistky a Circuit Breaker	14
2.3.7 Dovednosti (Skills)	15

2.3.8	Model Context Protocol (MCP servery)	15
2.3.9	Meta Harness a jeho bezpečnostní hranice	15
2.3.10	Škálování: hierarchičtí subagenti a DAG workflow	15
2.3.11	Zapojení člověka do smyčky (Human-in-the-loop)	16
3	Praktická část	17
3.1	Cíl a rozsah systému DarkFactory	17
3.2	Architektura a životní cyklus požadavku	17
3.3	Orchestrační jádro a validační infrastruktura	18
3.4	Systém revizních značek pro lidský dohled nad akademickým textem	18
4	Výsledky a diskuse	20
4.1	Sjednocení pracovních postupů a přenositelnost napříč doménami	20
4.2	Provozní metriky a spolehlivost agentních běhů	20
4.3	Poznatky a systémová úskalí z provozu	20
4.4	Diskuse: Porovnání architektur	21
4.5	Systémová a metodická omezení	21
5	Závěr	22
	Seznam příloh	23
A	Obsah přiloženého média	24
B	Schéma konfiguračního manifestu darkfactory.json	25
C	Sdílené workflow pro GitHub Actions	26
D	Systémové prompty plánovacího a kódovacího agenta	27
E	Protokol revizních značek v sazebním systému Typst	28
	Seznam zdrojů	30

Seznam obrázků a tabulek

Obrázek 1	Architektura autonomní ReAct smyčky (Reasoning + Acting) a tok dat mezi uživatelé, kontextem, modelem a výkonným prostředím.	14
Tabulka 1	Rozpoznávání prostředí podle souboru popisujícího balíček.	18

1 Úvod

1.1 Motivace a vymezení problému

- **Současný stav automatizace:** Sestavení programu, běh testů, statická analýza i nasazení do produkce jsou dnes plně automatizovány stroji. Úzké hrdlo procesu tvoří samotná modifikace zdrojového kódu — časová prodleva mezi zadáním požadavku a vytvořením otestované změny.
- **Koncept temné továrny (*Dark Factory*):** Průmyslový model plně automatizovaného provozu běžícího bez stálé lidské obsluhy (není nutné svítit). Cílem není vytlačení člověka (inženýr a konstruktér určují záměr a specifikaci), nýbrž úplná eliminace člověka z mechanických, opakujících se úkonů.
- **Limity stávajících nástrojů na bázi LLM:** Většina stávajících řešení (chatovací asistenti, doplňování kódu) řeší pouze izolovaný krok — návrh fragmentu kódu. Chybí ucelená integrace do vývojového cyklu: kontextové zasazení, exekuce v repozitáři, řešení syntaktických regresí a řízení deterministických záruk.
- **Ústřední inženýrská otázka:** Nezkoumáme triviální otázku, zda jazykový model dokáže napsat fragment kódu, nýbrž jaká kontrolní architektura (**harness**) musí model obklopovat, aby jeho výstupům bylo možné v produkčním repozitáři spolehlivě důvěřovat.

1.2 Cíl práce a výzkumné otázky

Hlavní cíl: Vymezit teoretické principy agentního inženýrství (*agentic engineering*) a navrhnout modulární architekturu řídicího harnessu pro automatizovaný vývoj softwaru se zachováním lidského dohledu v klíčových rozhodovacích bodech.

Dílčí cíle:

- Vymezit deterministické základy infrastruktury (správu verzí a kontinuální integraci).
- Analyzovat limity velkých jazykových modelů (dynamiku kontextového okna, jev Context Rot, ztrátovou kompresi a sémantický posun).
- Navrhnout architekturu řídicího harnessu zahrnující nástrojové smyčky (ReAct) s detekcí uvíznutí, rozpočtem tahů a bezpečnostním pískovištěm.
- Formalizovat mechanismy zapojení člověka do smyčky (*Human-in-the-loop*), schvalovací brány a protokol revizních značek pro dohled nad textovými výstupy.

Výzkumné otázky:

- **VO1 (Míra automatizace a role člověka):** Lze vývojový proces od zadání požadavku (GitHub Issue) po pull request strukturovat tak, aby role vývojáře spočívala výhradně v architektonickém dozoru a schvalování záměru (Human Gate), bez nutnosti ručního psaní rutinního kódu?

- **V02 (Řízení divergence a spolehlivost smyčky):** Jakými deterministickými mechanismy (stuck detection, rozpočet tahů, circuit breaker) lze v harnessu spolehlivě zabránit patologiím modelu (perseveraci, oscilaci a zacyklení v ReAct smyčce)?
- **V03 (Integrita paměti a eliminace sémantického posunu):** Jak spravovat kontextové okno agenta při komplexních úlohách, aby nedocházelo k degradaci pozornosti (Context Rot) a ztrátě architektonických invariantů při kompresi?

1.3 Metodika práce

Práce má teoreticko-architektonický a inženýrský charakter. Postup sleduje strukturu inženýrského cyklu:

- **1. Koncepční analýza:** Systematické zmapování limitů autoregresivních modelů, dynamiky kontextového okna, jevu Context Rot a rozhraní nástrojů.
- **2. Architektonický návrh:** Formulace modulárního modelu řídicího harnessu, správy stavu, exekučního pískoviště, bezpečnostních pojistek a orchestrace subagentů.
- **3. Kritické zhodnocení:** Porovnání navržených principů s volnými agentními smyčkami a vymezení provozních limitů autonomního inženýrství.

2 Teoretická část

2.1 Deterministická vývojová infrastruktura

2.1.1 Úvod do deterministické infrastruktury

- **Potřeba determinismu v agentním vývoji:** Jazykové modely generují stochastické výstupy s proměnlivou mírou spolehlivosti. Aby bylo možné začlenit autonomního agenta do produkčního repozitáře, musí být obklopen nekompromisní deterministickou infrastrukturou.
- **Repozitář jako stavový prostor:** Vývojový proces formalizujeme jako přechody mezi diskrétními stavy souborového systému.
- **Orientovaný acyklický graf (Git DAG) (1):**
 - **Uzly grafu:** Neměnné objekty revizí (*commits*) provázané kryptografickými hashy (SHA-1 či SHA-256) na své předchůdce.
 - **Hrany grafu:** Jednosměrné reference definující kauzální historii změn.
 - **Úplná lokální kopie:** Každý přispěvatel i agent disponuje celou historií projektu, což umožňuje nezávislé provádění i audit operací.

2.1.2 Větvě a větvová izolace

- **Větvě jako pohyblivé ukazatele (Refs):** Odlehčené ukazatele na konkrétní uzly v grafu revizí.
- **Izolace pracovní větve:** Agent operuje výhradně ve vyhrazené větvi (`feature/...` či `agent/...`) odbočené z hlavní linie (`main`).
 - **Ochrana produkčního kódu:** Pokusné mutace, dočasné mezistavy a syntaktické chyby modelu zůstávají striktně odděleny od stabilního kódu.
 - **Vyloučení interferencí:** Zamezení kolizím s rozpracovanou prací lidských vývojářů v repozitáři.
- **Deterministický audit trail:** Záznam každého kroku agenta jako atomického commitu se strojovými metadaty (identifikátor agenta, časový otisk, odkaz na issue).

2.1.3 Model pull requestu

- **Model pull requestu (PR / Merge Request):** Formalizovaný procesní uzel předkládající navržený diff kódu k posouzení před jeho integrací.
- **Komponenty rozhraní PR:**
 - Řádkový diff (přehledné zobrazení přidáných a odebraných řádků).
 - Výsledky automatických kontrol z integračního serveru.
 - Strukturovaný popis záměru a realizovaných změn vygenerovaný agentem.
- **Role v agentickém vývoji (Human Gate):** Hlavní schvalovací brána, v níž člověk provádí finální sémantickou revizi podle principu *Human-in-the-loop*.

2.1.4 Strategie slučování (Squash and Merge)

- **Slučovací strategie:** Topologický způsob začlenění pracovní větve do chráněné hlavní linie (`main`).
- **Rebase a Fast-Forward:** Přeskládání commitů do lineární historie; u agentních běhů však zanechává v historii množství drobných, neúspěšných pokusů.
- **Squash and Merge:** Sloučení celé sekvence dílčích mezikroků a ladicích pokusů modelu do jediného čistého uzlu.
 - **Eliminace šumu:** V hlavní větvi repozitáře zůstává pouze finální, ověřený přírůstek s kompletním souhrnem.
 - **Čistá historie:** Zjednodušení budoucího auditu a deterministického návratu změn (`git revert`).

2.1.5 Kontinuální integrace (CI)

- **Kontinuální integrace (CI) (2):** Praxe průběžného, automatického sestavování a testování každé navržené změny v izolovaném prostředí.
- **Deterministický arbitr správnosti:** V agentickém inženýrství plní CI nezastupitelnou roli neúprosného verifikátoru. Stochastický výstup LLM nepovažujeme za funkční kód, dokud neprojde exekutivním ověřením testy a kompilátorem.
- **Izolované běhové prostředí:** Každý testovací běh probíhá v čistém, předem definovaném kontejneru, což vylučuje závislost na lokálním stavu vývojářského počítače.

2.1.6 Požadované kontroly (Required Checks)

- **Požadované kontroly (Required Checks):** Množina automatických úloh v CI pipeline, jejichž úspěšné dokončení je podmínkou pro povolení sloučení PR:
 - **Statická analýza a linting:** Kontrola formátování, typové správnosti a dodržování architektonických pravidel.
 - **Jednotkové testy (Unit Tests):** Deterministické ověření izolovaných funkcí a tříd.
 - **Integrační a integrační testy:** Ověření vazeb mezi moduly a externími službami.
- **Pravidlo deterministického zakončení:** Každá kontrola musí skončit explicitním úspěchem či neúspěchem. Úloha, která se tiše přeskočí bez nahlášení výsledku, může chráněnou větev trvale zablokovat.
- **Reprodukovatelné artefakty:** Výstupy úspěšné pipeline (binární balíčky, knihovny, vysázená PDF dokumentace) vázané na neměnné značky (*tagy*) v historii gitu.

2.2 Kognitivní jádro a správa kontextového okna

2.2.1 Úvod do velkých jazykových modelů

- **Velké jazykové modely (LLM) (3):** Architektura dekodérového transformeru (*Decoder-only*, např. řady Claude, GPT, LLaMA, DeepSeek).

- **Stochastický autoregresivní generátor:** Model na základě zadané textové historie (kontextu) opakovaně predikuje nejpravděpodobnější následující symboly.
- **Role v agentním inženýrství:** Model nevystupuje jako orákulum se znalostí reálného světa, nýbrž jako generátor hypotéz, kódu a strukturovaných volání nástrojů řízený promptem a kontextem.

2.2.2 Tokeny, tokenizace a embedding

- **Tokeny:** Základní diskretní celočíselné jednotky, se kterými neuronová síť počítá (podmnožiny slov, slabiky, znaky).
- **Tokenizér:** Deterministický algoritmus (např. Byte-Pair Encoding, BPE) převádějící vstupní text na posloupnost tokenů a naopak.
- **Embedding:** Projekce tokenů do vícerozměrného vektorového prostoru, v němž geometrická vzdálenost odpovídá sémantické příbuznosti pojmů.
- **Jazyková asymetrie tokenizace:** Text v češtině spotřebovává kvůli bohaté flexi a diakritice 2× až 3× více tokenů než ekvivalent v angličtině.
 - **Inženýrské doporučení:** Vnitřní systémové prompty, technické plány i logy harnessu vést v angličtině pro minimalizaci nákladů a latence.

2.2.3 Tahy a správa KV cache

- **Tahy (*Turns*):** Diskretní kroky výměny informací v agentní smyčce:
 - **Tah uživatele / prostředí (*User/Environment Turn*):** Zadání úkolu nebo vnější událost.
 - **Tah modelu (*Model Turn*):** Odpověď modelu nebo emitování požadavku na nástroj.
 - **Tah vykonání nástroje (*Tool Execution Turn*):** Výsledek operace vrácený harnessu.
- **KV cache (*Key-Value Cache*):** Ukládání mezivýpočtů matic pozornosti klíčů a hodnot pro již zpracovanou historii tahů.
 - **Výpočetní úspora:** Inferenční engine při novém tahu nemusí přepočítávat celou historii od začátku.
- **Kontextové okno (*Context Window*):** Pevně limitovaná kapacita paměti modelu. Omezeno kvadratickou složitostí mechanismu pozornosti ($O(N^2)$ vzhledem k délce sekvence N) a velikostí paměti GPU akceleratorů.

2.2.4 Kompakce kontextu a ztrátová komprese

- **Kompakce historie (*Compaction*):** Vyzvání modelu k vytvoření syntetického souhrnu dosavadního průběhu sezení pro uvolnění kapacity kontextového okna.
- **Destruktivní ztrátová komprese:** Autoregresivní model při rekurzivním zkracování podléhá konfirmačnímu zkreslení (*confirmation bias*) a preferuje fakta odpovídající jeho vnitřním statistickým asociacím:

- **Vymazání deterministických detailů:** Nevratný zánik čísel řádků, signatur privátních funkcí, přesných cest v souborech a doslovných chybových hlášení kompilátoru.
- **Ztráta negativních omezení:** Zákazy (neměnit veřejné API, nepřidávat externí knihovny) bývají v souhrnu zevšeobecněny nebo zcela vypuštěny.

2.2.5 Sémantický posun (Semantic Drift)

- **Mechanismus posunu:** Kaskádové kumulování drobných zkreslení a halucinací při vícenásobné rekurzivní kompresi ($S_{k+1} = f(S_k, \Delta_k)$).
- **Efekt tiché pošty:** Drobné nepřesnosti z kola k jsou v kole $k + 1$ přijaty jako nezvratná historická fakta.
- **Důsledek pro repozitář:** Po několika cyklech komprese se vnitřní model reality agenta zcela rozejde se skutečným stavem zdrojového kódu v souborovém systému.

2.2.6 Alternativní paměťové architektury (RAG a stavový graf)

- **Hierarchická epizodická paměť (RAG):** Ukládání doslovné historie tahů a výpisů nástrojů do externí databáze; selektivní injekce pouze bezprostředně relevantních fragmentů do aktivního okna.
- **Persistentní graf stavu projektu (Project State Graph):** Udržování explicitního strukturovaného stavu repozitáře (změněné soubory, otevřené úkoly, výsledky testů, invarianty) mimo kontextové okno.
- **Selektivní prořezávání KV cache:** Tenzorové uvolňování paměti s udržením klíčových kotev pozornosti (*attention sinks*) na úrovni inference (StreamingLLM (4), H_2O (5)).

2.2.7 Degradace pozornosti (Context Rot)

- **Context Rot:** Degradace schopnosti modelu rovnoměrně využívat informace v dlouhém kontextovém okně (jev *Lost in the Middle* (6)).
- **Multi-Needle Reasoning:** Schopnost současně nalézt a logicky propojit několik na sobě závislých faktů napříč soubory; s rostoucí délkou kontextu prudce klesá.
- **Důsledek pro vývoj:** Ačkoliv model deklaruje podporu stovek tisíc tokenů, při komplexním křížovém refaktoringu ve velkém kontextu často přehlédne klíčové souvislosti.

2.2.8 Promptové inženýrství a negativní instrukce

- **Systémový prompt:** Základní direktiva definující identitu agenta, dostupné nástroje a mantinely (formát commitů, zákaz destruktivních příkazů) (7).
- **Few-shot a Chain-of-Thought (CoT):** Vzorové ukázky řešení a vedení modelu k explicitní formulaci mezikroků uvažování před samotným zápisem kódu.
- **Úskalí negativních instrukcí:** Modely často porušují zákazy formulované negací (např. „nemazat existující testy“), protože matice pozornosti (QK^T) asociativně aktivuje zakázané pojmy dříve, než autoregresní proces uplatní logický operátor negace.

- **Inženýrské řešení:** Afirmativní formulace pravidel (pozitivní vymezení povolených mantinelů) kombinovaná s deterministickou ochranou v harnessu (připojení chráněných souborů pouze pro čtení, blokace v CI).

2.3 Architektura řídicího harnessu a orchestrace

2.3.1 Úvod do řídicích harnessů


- **Vymezení pojmu harness:** Řídicí a dozorčí program obklopující inferenční jádro. Samotné inferenční jádro provádí pouze maticové násobení vah sítě; veškerou orchestraci řídí harness.
- **Funkce harnessu:**
 - Inicializace a správa sezení.
 - Konstrukce a dynamická injekce promptu.
 - Zajištění bezpečného běhu a izolace nástrojů.
 - Řízení stavových přechodů a vynucování bezpečnostních pojistek.

2.3.2 Autonomní agent vs. konverzační chatbot

- **Konverzační chatbot:**
 - Generuje pasivní textové odpovědi v uzavřeném rozhraní.
 - Nemá přímý přístup k souborovému systému ani k operačnímu systému.
 - Uživatel musí navržený kód manuálně zkopírovat, spustit a otestovat.
- **Autonomní agent:**
 - Vybaven sadou výkonných nástrojů (*tools*).
 - Aktivně čte repozitář, modifikuje soubory, spouští testy a interpretuje jejich výstupy.
 - Uzavřen v autonomní prováděcí smyčce, v níž iterativně reaguje na reálnou odezvu prostředí.

2.3.3 Prováděcí cyklus ReAct

- **ReAct smyčka (*Reasoning + Acting*) (8):** Čtyřfázový prováděcí cyklus znázorněný na Obrázek 1:
 1. **Rozvaha (*Thought*):** Analýza aktuálního stavu kontextu modelem a formulace nejbližšího záměru.
 2. **Volání nástroje (*Tool Call*):** Emitování strukturovaného požadavku na provedení konkrétní akce.
 3. **Vykonání a pozorování (*Observation*):** Bezpečný běh akce v harnessu a vložení výstupu do kontextu.
 4. **Navazující iterace:** Předložení aktualizovaného kontextu modelu v dalším tahu.



Obrázek 1: Architektura autonomní ReAct smyčky (Reasoning + Acting) a tok dat mezi uživatelem, kontextem, modelem a výkonným prostředím.

2.3.4 Běhové prostředí nástrojů a pískoviště (Sandbox)

- **Strukturované volání nástrojů (Tool / Function Calling):** Validace vstupů a výstupů proti JSON schémátům. Spolehlivé pro atomické operace, ale nese tokenovou režii schémat.
- **Přímé spouštění kódu (Code Execution):** Spouštění generovaných skriptů v sandboxu. Maximální flexibilita, avšak vyžaduje striktní bezpečnostní izolaci.

2.3.5 Patologie divergence: perseverace a oscilace

- **Perseverace a zacyklení:** Opakované emitování identického volání nástroje se stejnými argumenty (např. čtení neexistujícího souboru) i po obdržení chybové zprávy. V kontextu vzniká pravděpodobnostní atraktor, který nutí model k opakování chybného vzorce.
- **Oscilace a těkání (Thrashing):** Střídavé přepínání mezi dvěma protichůdnými zásahy (úprava modulu A rozbije modul B a následná oprava B rozbije A).
- **Nekontrolovaná spotřeba zdrojů (Context Runaway):** Rychlé vyčerpání kontextového okna i rozpočtu na volání API.

2.3.6 Deterministické pojistky a Circuit Breaker

- **Rozpočet tahů a nákladů (Step & Cost Budget):** Pevný limit maximálního počtu tahů $T_{\max}$ (typicky 25–50 kroků) a finanční strop pro tokeny; při překročení dochází k okamžitému zastavení inference.
- **Algoritmická detekce uvíznutí (Stuck Detection):** Výpočet kanonického hashe volání nástroje v čase t :

$$h_t = \text{hash}(\text{nástroj}, \text{canonicalize}(\text{argumenty}))$$

Harness v klouzavém okně posledních k tahů detekuje shodu $h_t = h_{t-1} = \dots = h_{t-k+1}$ nebo cyklické periody.

- **Dvoustupňová intervence:**
 - **1. stupeň:** Injekce syntetického varování rozbíjejícího pravděpodobnostní atraktor v matici pozornosti.
 - **2. stupeň (Circuit Breaker):** Tvrdé přerušení cyklu, automatický návrat změn v gitu na poslední stabilní commit (`git checkout`) a eskalace člověku.

2.3.7 Dovednosti (Skills)

- **Koncept dovedností (Skills):** Adresáře instrukcí a referencí se souborem `SKILL.md` (YAML frontmatter).
- **Efektivita kontextu:** Do výchozího systémového promptu se načítají pouze stručná metadata (název a popis role); detailní návod a skripty se načítají dynamicky až při explicitním vyvolání nástroje.
- **Skripty a záchytné body (Scripts & Hooks):** Deterministické skripty pro rutinní transformace kódu a událostní háčky vyvolávané při stavových přechodech harnessu.

2.3.8 Model Context Protocol (MCP servery)

- **Model Context Protocol (MCP) (9):** Otevřený standard propojující jazykové modely s externími nástroji a datovými zdroji.
- **Protokolové rozhraní:** Komunikace probíhá přes protokol JSON-RPC (prostřednictvím `stdio` nebo `Server-Sent Events / SSE`).
- **Architektonické oddělení:** Striktní oddělení běhového prostředí agenta od implementace nástrojů. MCP servery fungují jako samostatné, znovupoužitelné komponenty běžící mimo jádro harnessu.

2.3.9 Meta Harness a jeho bezpečnostní hranice

- **Koncept Meta Harness (10):** Samořízená evoluce a adaptace harnessu samotným agentem (úprava vlastních pravidel, konfigurací a promptů).
- **Využití:** Vhodné pro osobní agenty maximalizující autonomii při řešení unikátních problémů.
- **Rizika:** V podnikovém nasazení vyžaduje striktní deterministické ohraničení vylučující svévolnou modifikaci systémových pravidel.

2.3.10 Škálování: hierarchičtí subagenti a DAG workflow

- **Subagenti (Subagents):** Hierarchická dekompozice úlohy orchestrátorem na specializované agenty (průzkumník repozitáře, plánovač, kódovací dělník). Kontext subagenta

je po dokončení zahozen a orchestrátoru je předán pouze čistý výsledek, což chrání primární kontext před znečištěním (*context pollution*).

- **Pracovní postupy jako grafy (DAG / Graph Engineering):** Formalizace fází životního cyklu jako orientovaného acyklického grafu (detekce → plán → kód → testy → schválení). Hrany definují striktní závislosti (`needs`); selhání v libovolném uzlu okamžitě zastaví navazující kroky.

2.3.11 Zapojení člověka do smyčky (Human-in-the-loop)

- **Princip Human-in-the-loop:** Cílem není nekritická plná autonomie, nýbrž automatizace rutinních a mechanických kroků v kombinaci s lidským rozhodováním tam, kde je změna nevratná nebo kde chybí jednoznačné algoritmické měřítko správnosti.
- **Lidské schvalovací brány (Human Gates):** Formální procesní uzly, v nichž se automatický běh pozastaví a vyčká na autorizaci operátora.
 - **Dvoufázové schvalování:**
 - **1. brána (Záměr a plán):** Člověk autorizuje technický plán a rozpad požadavku dříve, než agent začne modifikovat kód.
 - **2. brána (Sémantická revize):** Člověk provádí finální kontrolu diffu v pull requestu před jeho začleněním do hlavní větve.
 - **Prevence únavy z revizí (Review Fatigue):** Vyvážená frekvence kontrol — zamezení mikromanagementu na úrovni jednotlivých souborů při zachování kontroly nad celkovým architektonickým směrem.
- **Dohledatelnost původního zadání:** Trvalé uchovávání doslovného znění požadavku (GitHub Issue) bez ztrátových parafrází modelem, což brání vymizení okrajových podmínek v průběhu vývoje.
- **Transparentnost selhání a deterministická eskalace:** Zákaz tichého pohlcování chyb či halucinovaných omluv při selhání. Při vyčerpání rozpočtu tahů nebo selhání testů harness vygeneruje strukturovaný diagnostický incident (diff, chybové hlášení, stav kontextu) a předá jej vývojáři k manuálnímu zásahu.

3 Praktická část

3.1 Cíl a rozsah systému DarkFactory

- **Systém DarkFactory** (11): Agentní harness instalovatelný jako aplikace pro platformu GitHub (GitHub App).
- **Cíl systému:** Maximalizace automatizace rutinních fází softwarového inženýrství:
 - Sémantická analýza požadavků v GitHub Issues.
 - Technické plánování a dekompozice úlohy.
 - Generování a úprava zdrojového kódu.
 - Běh validačních testů a automatické opravy chyb.
 - Otevření strukturovaného pull requestu.
- **Míra autonomie:** Kooperativní model se zapojením člověka (*Human-in-the-loop*). Vzhledem ke stochastické povaze LLM nelze systém označit za plně autonomní; modely nemohou nést konečnou architektonickou odpovědnost.
- **Dělbba rolí:**
 - **Autonomní agent:** Kognitivně rutinní a mechanické operace (průzkum souborů, syntéza kódu, řešení syntaktických regresí, běh testů).
 - **Lidský inženýr:** Vymezení záměru (co a proč stavět), schvalování technických plánů a finální sémantická kontrola kódu v PR.

3.2 Architektura a životní cyklus požadavku

- **Architektonická modularita:** Striktní oddělení deklarativního konfiguračního manifestu klientského repozitáře od sdílené orchestrační logiky.
- **Hermetické běhové prostředí:** Izolovaný běh úloh v kontejnerech se zamčenými verzemi závislostí a nástrojů.
- **Životní cyklus požadavku (Stavový automat / DAG):**
 - **1. Příjem:** Detekce nového zadání v GitHub Issues.
 - **2. Plánování:** Analýza kódu a návrh kroků implementace.
 - **3. Lidská brána 1:** Schválení plánu vývojářem.
 - **4. Implementace:** Autonomní editace souborů v izolované větvi.
 - **5. Validace:** Běh testů a kontrol v CI s automatickou samoopravou chyb.
 - **6. Vystavení PR:** Otevření pull requestu s popisem a diffem.
 - **7. Lidská brána 2:** Finální kontrola a schválení člověkem.
 - **8. Integrace:** Automatické sloučení do hlavní větve (*squash and merge*).

^{*}Pojem **hermetické prostředí** označuje výpočetní prostředí zcela izolované od nekontrolovaných stavů hostitelského systému a sítě. Veškeré nástroje, knihovny a závislosti jsou explicitně uzamčeny na konkrétních verzích, což zaručuje determinismus a reprodukovatelnost.

- **Dvouúrovňová detekce projektů:**

- **Prostředí (*Environment*):** Určuje vyžadované binární nástroje a balíčkovací manažery podle detekovaných souborů (viz Tabulka 1).
- **Doména (*Domain*):** Určuje způsob řízení výstupů (doména programového kódu vs. textová sazba a dokumentace).

Soubor	Prostředí	Doména
<code>pyproject.toml</code>	Python	kód
<code>Cargo.toml</code>	Rust	kód
<code>package.json</code>	Node	kód
<code>go.mod</code>	Go	kód
<code>typst.toml</code>	Typst	text
<code>.latexmkrc</code>	LaTeX	text
<code>lakefile.toml</code>	Lean	matematika

Tabulka 1: Rozpoznávání prostředí podle souboru popisujícího balíček.

- **Deklarativní manifest:** Umožňuje automaticky detekované parametry deklarativně přepsat či rozšířit (např. o explicitní cesty k písmům nebo dodatečné integrační kontroly).

3.3 Orchestrační jádro a validační infrastruktura

Klíčové operační mechanismy orchestračního jádra:

- **Rotace poskytovatelů LLM:** Úkoly jsou definovány nezávisle na formátu konkrétního poskytovatele. Při vyčerpání kvóty nebo výpadku API primárního modelu harness automaticky přepne na navazující model v rotačním žebříčku, což eliminuje prostoje pipeline.
- **Deterministické ověřování změn:** Každý zásah do kódu podléhá požadovaným kontrolám v CI. Úlohy končí explicitním stavem, čímž brání zablokování větve v důsledku přeskočených kontrol.
- **Správa nastavení jako kód (*Config as Code*):** Pravidla ochrany větví, konfigurace linterů i projektové nástěnky (GitHub Projects) jsou definovány deklarativně a podléhají verzování v gitu.
- **Automaticky odvozovaná živá dokumentace (*Living Documentation*):** Dokumentace a specifikace jsou generovány přímo ze zdrojového kódu a strukturovaných inline komentářů s automatickou validací v CI.

3.4 Systém revizních značek pro lidský dohled nad akademickým textem

Protokol vizuálních revizních značek pro formát Typst formalizuje dohled člověka nad generovaným textem:

1. Postranní revizní panely (*Callouty*):

- `#note[...]` (zelený): Konstruktivní náměty na vylepšení, doplnění diagramů a praktické vazby.
- `#issue[...]` (červený): Věcné nesrovnalosti, logické mezery, překlepy a duplicitní obsah.
- `#alert[...]` / `#struct-alert[...]` (žlutý): Strukturální nevyváženost, chybějící sekce a osnovové neshody.
- `#critique[...]` (oranžový): Hlubková oponentura, slepá místa, zpochybnění neověřených předpokladů k obhajobě.
- `#blue-note[...]` (modrý): Metodické vymezení, rozsah práce a konceptuální mantinely zadání.

2. Textové revizní funkce v toku textu:

- **Neověřený koncept** (`#draft[...]` / `#unconfirmed[...]`): Žluté podbarvení — koncept čekající na posouzení a revizi autorem.
- **Nově přidaný text** (`#added[...]`): Zelené podbarvení — nově vygenerovaný text začleněný agentem.
- **Potvrzený text** (`#confirmed[...]`): Modré podbarvení — text potvrzený uživatelem, čekající na finální integraci.
- **Navrženo k odstranění** (`#removed[...]`): Červené přeškrtnutí — zastaralý text navržený ke smazání.
- **Srovnávací diff** (`#diff(old, new)`): Červený původní text přeškrtnutý následovaný zeleným novým textem.
- **Čistý neoznačený text**: Finální, autorsky schválený text v hlase autora bez podbarvení.

4 Výsledky a diskuse

4.1 Sjednocení pracovních postupů a přenositelnost napříč doménami

Architektonické principy centralizovaného harnessu:

- **Centralizace pracovních postupů:** Klientské repozitáře neudrží vlastní izolované skripty; exekuci delegují na centrální znovupoužitelné šablony a specifičnost projektu vymezují v deklarativním manifestu.
- **Údržbová složitost $O(1)$:** Bezpečnostní oprava či aktualizace v harnessu je provedena jednou a spotřebitelské projekty ji přebírají posunem připnuté verze ($O(1)$ oproti $O(N)$ manuálním úpravám v každém repozitáři zvlášť).
- **Statická kontrola jádra:** Jádro harnessu podléhá striktní typové kontrole a jednotkovému testování před každým vydáním.
- **Omezení jediného bodu selhání (SPOF):** Projekty odkazují na neměnný kryptografický SHA hash commitu či sémantický tag, což vylučuje nechtěné regresní změny.
- **Konzistentní agentní prostředí:** Jednotný životní cyklus požadavků, správa kontextu, rotace modelů i vyhodnocení validačních bran napříč všemi projekty.
- **Oddělení prostředí od domény:**
 - **Doména programového kódu:** Kompilace, statická analýza, jednotkové testy a měření pokrytí.
 - **Doména textu a dokumentace:** Sazební kompilace, kontrola terminologie a generování auditovatelných PDF artefaktů.
- **Univerzální orchestrační automat:** Řídící harness obsluhuje obě domény shodným stavovým automatem bez větvení integrační logiky.

4.2 Provozní metriky a spolehlivost agentních běhů

4.3 Poznatky a systémová úskalí z provozu

Poznatky z nasazení autonomních agentů v CI:

- **Řízení souběžnosti a větvené zámky:** Paralelní integrační běhy vyžadují striktní zámky na úrovni větví, aby nedocházelo ke kolizím a uvážnutí workflow.
- **Transparentnost hlášení selhání:** Zákaz tichého pohlcování výjimek; každá chyba nástroje nebo API musí být zaznamenána do kontextu a eskalována člověku. Tiché maskování chyb vede k masivním halucinacím modelu.
- **Deklarativní detekce prostředí:** Vyloučení implicitních předpokladů o repozitáři; veškeré kroky se deterministicky odvozují z přítomnosti souborů a deklarativního manifestu.

4.4 Diskuse: Porovnání architektur

Porovnání navrženého harnessu se současnými platformami (SWE-agent (8), Devin, Copilot Workspace):

- **Deterministický DAG vs. nekonečná smyčka:**
 - **Volné smyčky (SWE-agent):** Monolitický model v interaktivním terminálu sám rozhoduje o ukončení; při uvíznutí v atraktoru snadno vyčerpá rozpočet tokenů.
 - **Navržený harness:** Model je uzavřen do deterministického grafu (DAG) se striktně alokovaným rozpočtem tahů na každou fázi a izolací kontextu.
- **Granularita lidského dohledu:**
 - **Jednorázový přístup:** Přímé vygenerování celého PR; při špatném pochopení zadání vede ke stovkám řádků vadného kódu a únavě vývojáře z revizí (*review fatigue*).
 - **Dvoufázové schvalování:** Člověk autorizuje záměr a technický plán dříve, než agent začne zasahovat do repozitáře.
- **Bezpečnost a hermetičnost:**
 - **Lokální stroje:** Riziko poškození prostředí či úniku tajemství při spouštění netestovaného kódu.
 - **Efemérní CI kontejnery:** Běh v izolovaném sandboxu s minimálními oprávněními tokenů a auditovatelným protokolem všech operací.

4.5 Systémová a metodická omezení

Limity navržené architektury:

- **1. Hranice deterministické verifikovatelnosti:** Autonomie je spolehlivá pouze u objektivně testovatelných změn (kód, testy, typy). U subjektivních úloh (UX ergonomie, grafický design, stylistická formulace textu) zůstává role modelu asistenční a validaci provádí člověk.
- **2. Propustnost a dostupnost inferenčních API:** Rotační žebříček tlumí lokální výpadky, avšak globální kvóty a latence cloudových poskytovatelů tvoří pevný strop průchodnosti pipeline.
- **3. Absence vícevláknového řešení konfliktů:** Souběžná práce mnoha autonomních agentů a lidí nad týmiž soubory a řešení komplexních merge konfliktů představuje otevřenou výzvu pro navazující výzkum.

5 Závěr

Seznam příloh

A	Obsah přiloženého média	24
B	Schéma konfiguračního manifestu darkfactory.json	25
C	Sdílené workflow pro GitHub Actions	26
D	Systémové prompty plánovacího a kódovacího agenta	27
E	Protokol revizních značek v sazebním systému Typst	28

A Obsah přiloženého média

Odevzdaný archiv obsahuje kompletní zdrojové soubory práce, sazební šablonu, řídicí skripty a zdrojový kód autonomního systému DarkFactory.

```
mono-OdbornaPrace/
├─ prace/                                # Rukopis a sazba odborné práce
│   └─ kapitoly/                         # Texty jednotlivých kapitol (01-uvod
až 06-prilohy)
│   └─ lib/odborna-prace.typ            # Sazební šablona, recenzní značky a
formátování GJKT
│   └─ img/                             # Vektorová procesní schémata (SVG) a
grafické podklady
│   └─ fonts/                           # Metricky shodná patková písma
(Caladea)
│   └─ bib/references.bib               # Bibliografická databáze citovaných
zdrojů
│   └─ scripts/                         # Pomocné a náhledové skripty
│   └─ main.typ                         # Hlavní řídicí dokument sazby
│   └─ metadata.typ                     # Údaje o autorovi, vedoucím a
anotace
│   └─ Makefile                         # Příkazy pro automatizovanou
kompilaci a kontrolu
├─ darkfactory/                         # Zdrojový kód systému DarkFactory
(submodul)
│   └─ .github/workflows/              # Sdílené šablony kontinuální
integrace
│   └─ src/                            # Výkonné orchestrační jádro systému
├─ out/prace.pdf                       # Výsledný vysázený tiskový dokument
v PDF
└─ README.md                           # Dokumentace a návod na reprodukci
prostředí
```

Výpis 1: Stromová adresářová struktura odevzdaného elektronického archivu a doprovodných repozitářů.

B Schéma konfiguračního manifestu darkfactory.json

C Sdílené workflow pro GitHub Actions

D Systémové prompty plánovacího a kódovacího agenta

E Protokol revizních značek v sazebním systému Typst

Tato příloha uvádí referenční definici a použití vizuálních revizních značek pro řízení a dohled nad generovaným textem v sazebním formátu Typst.

```
#import "lib/odborna-prace.typ": note, issue, alert, critique, added,
draft, confirmed, diff

// --- 1. Panely na okraji textu (Callouty) ---
#note[Doplňte porovnání rychlosti kompilace mezi verzemi 0.1 a 0.2.]
#issue[Chybná signatura funkce: chybí povinný parametr timeout.]
#alert[Sekce postrádá shrnutí naměřených výsledků před diskusí.]
#critique[Metodologická absence baseline prokazující přínos nového
modulu.]
#blue-note[Metodické vymezení: rozsah práce a oddělení agentního
inženýrství od strojového učení.]

// --- 2. Textové revizní funkce (zvýraznění v toku textu) ---
#draft[Tento odstavec tvoří neověřený koncept čekající na schválení.]
#added[Nově vygenerovaná sekce automaticky začleněná agentem.]
#confirmed[Uživatelem zkontrolovaný text, který ještě nebyl finalizován.]
#removed[Zastaralý text navržený k odstranění.]
#diff[Původní chybné znění textu.][Nové opravené znění textu po revizi.]
```

Výpis 2: Ukázka zápisu a použití revizních značek a textových funkcí v jazyce Typst.

Vizuální reprezentace jednotlivých prvků v sazbě

Pro přehlednost jsou níže uvedeny reálné ukázky jednotlivých revizních panelů a textových funkcí v jejich finální vizuální podobě:

Ukázky textových zvýrazňovacích a srovnávacích funkcí v toku odstavce:

- **Neověřený koncept** (`#draft` / `#unconfirmed`): Tento text představuje koncept čekající na posouzení autorem.
- **Nově přidáný text** (`#added`): Tato pasáž byla nově vygenerována autonomním agentem na základě požadavku.
- **Potvrzený text** (`#confirmed`): Text byl předběžně odsouhlasen uživatelem, čeká na finální začištění.
- **Navrženo k odstranění** (`#removed`):
- **Srovnávací diff** (`#diff`): Nové přesné, fakticky a formálně ověřené znění pasáže.
- **Čistý neoznačený text**: Představuje finální, autorsky schválený text v hlase autora bez jakéhokoliv podbarvení.

Role značek v lidském dohledu:

- **Čistý neoznačený text**: Schválený autorský text v hlase autora.

- **Žluté podbarvení (#unconfirmed)**: Neověřený koncept čekající na lidské posouzení.
- **Zelené podbarvení (#added)**: Nově vygenerované návrhy agenta.
- **Modré podbarvení (#confirmed)**: Uživatelem odsouhlasený text.
- **Srovnávací diff (#diff)**: Transparentní vizualizace navržených oprav.
- **Postranní panely (Callouty)**: Striktní oddělení námětů, chyb a oponentury od těla textu.

Seznam zdrojů

1. CHACON, Scott a STRAUB, Ben. *Pro Git*. 2. New York : Apress, 2014. IS-BN 978-1-4842-0076-6.
2. HUMBLE, Jez a FARLEY, David. *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*. Boston : Addison-Wesley, 2010. ISBN 978-0-321-60191-9.
3. VASWANI, Ashish, SHAZEER, Noam, PARMAR, Niki, USZKOREIT, Jakob, JONES, Llion, GOMEZ, Aidan N., KAISER, Łukasz a POLOSUKHIN, Illia. Attention Is All You Need. *arXiv preprint arXiv:1706.03762*. Online. 2017. Available from: <https://arxiv.org/abs/1706.03762>
4. XIAO, Guangxuan, TIAN, Yuandong, CHEN, Beidi, HAN, Song a LEWIS, Mike. Efficient Streaming Language Models with Attention Sinks. *arXiv preprint arXiv:2309.17453*. Online. 2023. Available from: <https://arxiv.org/abs/2309.17453>
5. ZHANG, Zhenyu, SHENG, Ying, ZHOU, Tianyi, CHEN, Tianlong, ZHENG, Lianmin, CAI, Ruisi, SONG, Zhao, TIAN, Yuandong, RÉ, Christopher, BARRETT, Clark, WANG, Zhangyang a CHEN, Beidi. H2O: Heavy-Hitter Oracle for Efficient Generative Inference of Large Language Models. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 34661–34730. Available from: <https://arxiv.org/abs/2306.14048>
6. LIU, Nelson F., LIN, Kevin, HEWITT, John, PARANJAPE, Ashwin, BEVILACQUA, Michele, PETRONI, Fabio a LIANG, Percy. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*. Online. 2024. Vol. 12, p. 157–173. Available from: <https://arxiv.org/abs/2307.03172>
7. ANTHROPIC. Prompt Engineering overview. Online. 2026. Available from: <https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview>
8. YAO, Shunyu, ZHAO, Jeffrey, YU, Dian, DU, Nan, SHAFRAN, Izhak, NARASIMHAN, Karthik a CAO, Yuan. ReAct: Synergizing Reasoning and Acting in Language Models. *arXiv preprint arXiv:2210.03629*. Online. 2022. Available from: <https://arxiv.org/abs/2210.03629>
9. ANTHROPIC. Model Context Protocol documentation. Online. 2026. Available from: <https://modelcontextprotocol.io/docs/2026-07-28/getting-started/intro#explore-mcp>
10. Meta Harness: End to end optimization of Agent Harnesses. *arXiv preprint arXiv:2603.28052*. Online. 2026. Available from: <https://arxiv.org/abs/2603.28052>
11. MARIUS, Patrik. DarkFactory: autonomous, governed software engineering pipelines. Online. 2026. [Accessed 8 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory>
12. Deepseek Harness. *arXiv preprint arXiv:2608.25512*. Online. 2026. Available from: <https://arxiv.org/abs/2608.25512>

13. DAO, Tri, FU, Daniel Y., ERMON, Stefano, RUDRA, Atri a RÉ, Christopher. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. *Advances in Neural Information Processing Systems*. Online. 2022. Vol. 35, p. 16344–16359. Available from: <https://arxiv.org/abs/2205.14135>
14. AINSLIE, Joshua, LEE-THORP, James, JONG, Michiel de, ZEMLYANSKIY, Yury, LEBRÓN, Federico a SANGHAI, Sumit. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints. *arXiv preprint arXiv:2305.13245*. Online. 2023. Available from: <https://arxiv.org/abs/2305.13245>